



Excelencia que trasciende

DELVALLE
GRUPO EDUCATIVO

LAB 2

Aprendizaje por Refuerzo

Santiago Pereira - 22318
Nancy Mazariegos - 22513
Brandon Reyes - 22992
Hugo Rivas - 22500

Task 1

1. El espacio de estados $\mathcal{S}$: ¿qué variables definen completamente la situación del sistema en un instante dado? Justifiquen cada variable incluida y cada variable omitida. Para cada variable omitida, argumenten qué supuesto están haciendo y qué consecuencia tiene ese supuesto sobre la validez del modelo.

El estado puede representarse como:

$$s = (p, d, q, e)$$

donde:

- p: piso en el que se encuentra el ascensor.
- d: dirección actual, ya sea hacia arriba, abajo o detenido.
- q: demanda pendiente por piso.
- e: indicador de emergencia.

Estas variables permiten saber dónde está el ascensor, hacia dónde se mueve y qué solicitudes deben atenderse. Se omiten variables como peso exacto de pasajeros, fallas mecánicas y duración de apertura de puertas, asumiendo que su efecto es pequeño o constante. Esta simplificación reduce el tamaño del modelo, pero hace que la representación sea menos realista.

2. El espacio de acciones $\mathcal{A}$: definan las acciones disponibles para el sistema de control. Argumenten si el espacio debe ser discreto o continuo para este dominio, y si existen acciones que deben restringirse en ciertos estados y cómo se modela esa restricción.

El espacio es discreto:

$$\mathcal{A} = \{\text{subir}, \text{bajar}, \text{detenido}\}$$

No se puede subir desde el piso 5 ni bajar desde el piso 1. Estas restricciones se modelan mediante un conjunto de acciones válidas para cada estado.

3. La función de recompensa $r(s, a, s')$: diseñen una función que capture el objetivo operacional real. Consideren al menos los siguientes objetivos potencialmente conflictivos: minimizar tiempo de espera promedio, priorizar pisos de emergencia, y minimizar consumo energético. Argumenten cómo ponderan esos objetivos y qué consecuencias tendría una ponderación incorrecta sobre el comportamiento del agente.

Posible función es:

$$r = -W - 5E - 0.5M + 15A$$

donde:

- W: tiempo de espera acumulado.
- E: espera de solicitudes de emergencia.
- M: movimiento del ascensor.

- A: solicitud atendida.

Ejemplos:

- Atender una solicitud: +15.
- Cada unidad de espera normal: -1.
- Cada unidad de espera de emergencia: -5.
- Cada movimiento: -0.5.

Se asigna una recompensa de +15 por atender una solicitud, ya que completar el traslado de pacientes, camillas o personal médico representa el objetivo principal del sistema. Este valor supera el costo de movimiento y espera, incentivando al ascensor a responder a las llamadas. Sin embargo, las emergencias conservan una penalización alta para garantizar que sean atendidas con mayor prioridad.

4. La función de transición $p(s' | s, a)$: argumenten si el entorno es determinista o estocástico. Si es estocástico, identifiquen las fuentes de aleatoriedad y escriban al menos cuatro transiciones concretas con sus probabilidades justificadas.

El entorno es estocástico porque pueden aparecer nuevas solicitudes de forma impredecible.

Ejemplos:

$$P((p + 1, d, q, e) | s, \text{subir}) = 0.80$$

El ascensor sube y no aparece una nueva llamada.

$$P((p + 1, d, q', e) | s, \text{subir}) = 0.15$$

El ascensor sube y aparece una nueva solicitud normal.

$$P((p + 1, d, q', 1) | s, \text{subir}) = 0.04$$

El ascensor sube y aparece una solicitud de emergencia.

$$P((p, d, q, e) | s, \text{subir}) = 0.01$$

El ascensor permanece en el mismo piso por demora de puertas o bloqueo temporal.

Las probabilidades suman 1.

5. El factor de descuento γ : propongan un valor y justifiquenlo en términos del dominio, no solo matemáticamente. ¿Cómo cambia la política óptima si γ es cercano a 0 versus cercano a 1 en este contexto específico?

Se propone:

$$\gamma = 0.90$$

Este valor permite considerar las consecuencias futuras, como evitar que se acumulen solicitudes y priorizar emergencias, sin dar demasiado peso a eventos muy lejanos.

Task 2:

1. Para el MDP que diseñaron, ¿cuántas políticas deterministas posibles existen? Calculen el valor exacto y argumenten por qué la enumeración exhaustiva es inviable incluso para este problema relativamente pequeño.

Una política determinista asigna una acción a cada estado, por lo que la cantidad total de políticas posibles es $|A|^{|S|}$. Con nuestro diseño:

$$|S| = 5 \text{ (pisos)} \cdot 3 \text{ (dirección)} \cdot 2^5 \text{ (demanda por piso)} \cdot 2 \text{ (emergencia)} = 960$$

$$|A| = 3 \text{ (subir, bajar, detenido)}$$

$$\text{Número de políticas deterministas} = 3^{960} \approx 1.4 \times 10^{458}$$

Aunque el edificio tiene únicamente 5 pisos, la explosión combinatoria aparece principalmente por el vector de demanda pendiente ($2^5 = 32$ combinaciones), multiplicado por las demás variables. Enumerar y evaluar cada política es inviable: incluso si evaluar una tomara un nanosegundo, el tiempo total superaría por muchos órdenes de magnitud la edad del universo. Por eso se justifica utilizar Policy Iteration y Value Iteration, que aprovechan la estructura recursiva de la ecuación de Bellman y no requieren recorrer el espacio completo de políticas.

2. Dado que T^π es una contracción con factor γ , ¿cuántas iteraciones de Policy Evaluation necesitan teóricamente para reducir el error inicial a menos de $\theta = 0.01$, asumiendo un error inicial de $\|V_0 - V^\pi\|_\infty \leq R_{\max} / (1 - \gamma)$?

Partiendo de la cota de convergencia geométrica del operador de contracción:

$$\|V_k - V^\pi\|_\infty \leq \gamma^k \cdot \|V_0 - V^\pi\|_\infty \leq \gamma^k \cdot R_{\max} / (1 - \gamma)$$

Queremos que el lado derecho sea menor que θ , entonces:

$$\gamma^k \cdot R_{\max} / (1 - \gamma) < \theta \Rightarrow k > \ln(\theta (1 - \gamma) / R_{\max}) / \ln(\gamma)$$

Sustituyendo $\gamma = 0.9$, $R_{\max} = 15$ y $\theta = 0.01$:

- Cota inicial del error: $R_{\max} / (1 - \gamma) = 15 / 0.1 = 150$

- $\theta (1 - \gamma) / R_{\max} = 0.01 \cdot 0.1 / 15 \approx 6.67 \times 10^{-5}$

- $k > \ln(6.67 \times 10^{-5}) / \ln(0.9) \approx -9.616 / -0.1054 \approx 91.27$

Se necesitan al menos 92 iteraciones de Policy Evaluation para garantizar que el error caiga por debajo de 0.01. Es una cota de peor caso; en la práctica la convergencia suele ocurrir antes, ya que V_0 normalmente no se encuentra tan lejos del punto fijo como la cota conservadora asume.

3. Para su MDP específico, ¿anticipan que Policy Iteration o Value Iteration convergerá más rápido en términos de tiempo de cómputo total? Justifiquen su respuesta considerando el tamaño del espacio de estados, el número de acciones, y el trade-off entre costo por iteración y número de iteraciones hasta convergencia.

Anticipamos que Policy Iteration convergerá más rápido en tiempo total, aun cuando cada una de sus iteraciones sea más costosa que una iteración de Value Iteration.

Value Iteration realiza una actualización barata por estado (un máximo sobre las $|A| = 3$ acciones), pero necesita del orden de 90 pasadas completas para alcanzar la tolerancia dada, y ese número aumenta rápidamente si γ se acerca a 1. Policy Iteration, en cambio, suele converger en pocas iteraciones externas (típicamente menos de una decena en problemas de este tamaño), y cada iteración incluye una Policy Evaluation que sobre $|S| = 960$ estados es perfectamente manejable, incluso resolviendo el sistema lineal exacto.

Por lo tanto, sabemos que VI realiza muchas iteraciones baratas, mientras que PI realiza pocas iteraciones caras. Con 960 estados, 3 acciones y $\gamma = 0.9$, el balance favorece a Policy Iteration. Esta predicción se contrastará empíricamente en la Task 4.